

Aplicação de técnicas de Reinforcement Learning para melhorar a precisão da estimativa do SOC em cenários dinâmicos.

Gabriel Vidal Schneider, Julian Ballestros Ramos, Vitor Solieri do Vale,
Yejin Chung

^a*Departament of Science Computer, Pontificia Universidade Católica do Paraná
(PUCPR), Curitiba, 80230-901, Parana, Brazil*

Abstract

Este trabalho investiga a aplicação de técnicas de Aprendizado por Reforço na estimativa do Estado de Carga (*State of Charge - SOC*) de baterias de íon de lítio em cenários dinâmicos. O estudo utiliza uma base de dados experimental composta por seis células com diferentes níveis de degradação. Como o *SOC* não estava explicitamente disponível na base, foi realizada uma etapa de pré-processamento para identificação dos ciclos de descarga e cálculo do SOC por meio do método de Contagem de Coulombs (*Coulomb Counting*). Duas abordagens foram avaliadas: uma rede neural recorrente do tipo *Long Short-Term Memory (LSTM)*, utilizada como modelo de referência, e um modelo de Aprendizado por Reforço baseado no algoritmo *Proximal Policy Optimization (PPO)*. O desempenho dos modelos foi avaliado por meio da métrica *Root Mean Squared Error (RMSE)*. Os resultados demonstraram que o modelo LSTM apresentou desempenho consistente entre diferentes baterias, com valores de RMSE entre 0,181 e 0,189, evidenciando boa capacidade de generalização. Já o modelo baseado em Aprendizado por Reforço apresentou resultados competitivos para células específicas, além de demandar menor tempo de treinamento. Os resultados indicam que o Aprendizado por Reforço representa uma alternativa promissora para a estimativa do SOC, especialmente em aplicações que exigem adaptação a condições operacionais específicas e maior eficiência computacional.

Keywords: Estado de Carga; Baterias de Íon de Lítio; Aprendizado por Reforço; Long Short-Term Memory; Proximal Policy Optimization; Sistemas de Gerenciamento de Baterias.

1. Introdução

A crescente adoção de veículos elétricos e sistemas de armazenamento de energia baseados em baterias de íon de lítio tem impulsionado pesquisas relacionadas ao monitoramento e gerenciamento dessas baterias. Nesse contexto, garantir o funcionamento seguro, eficiente e durável das baterias tornou-se um dos principais desafios tecnológicos [1].

Um dos parâmetros mais importantes para o gerenciamento de baterias é o Estado de Carga (State of Charge – SOC). O SOC representa a quantidade de carga elétrica disponível em uma bateria em relação à sua capacidade nominal, sendo geralmente expresso em porcentagem [2].

Esse parâmetro é amplamente utilizado em sistemas de gerenciamento de baterias (Battery Management Systems – BMS)[2], auxiliando no controle de carga e descarga, na estimativa de autonomia e na prevenção de condições de operação que possam degradar a bateria.

Com o constante aumento de uso e interesse em baterias elétricas, a determinação precisa do SOC se tornou um ponto crucial para o monitoramento da saúde e do uso dessas baterias, por isso diversos métodos foram criados para esse objetivo[3].

Contudo, estes métodos têm o problema no qual precisam de longos períodos de descanso para o equilíbrio dos processos eletroquímicos internos da bateria antes de terem leituras precisas, além de não serem capazes de lidar com o comportamento dinâmico dos dispositivos e serem limitados no escopo de cenários [3].

Ao buscar maneiras práticas de entender o comportamento do Estado da carga em baterias de íon de lítio diversas abordagens são realizadas. Dentre elas algumas no ramo de Deep Learning utilizando técnicas como Long Short Term Memory (LSTM) ou Deep Neural Network (DNN) para a identificação desses padrões [2].

Além de Deep Learning, outro ramo muito explorado é o Reinforcement Learning, o qual é baseado em um sistema de políticas e recompensas[4]. Sua vantagem está no fato de que ele é capaz de aprender diretamente dos dados operacionais sem uma estrutura fixa prévia, adquirindo estratégias de decisão via experiência, eficaz para sistemas dinâmicos [3]. É uma técnica, inclusive, especialmente útil para aplicações de controle de carregamento devido a sua capacidade de decisão contínua [5].

Este trabalho tem como objetivo investigar a aplicação de técnicas de Reinforcement Learning na estimativa e no gerenciamento do Estado de Carga (SOC) em baterias de íon de lítio. A pesquisa busca responder se essa abordagem é capaz de atuar de forma eficiente em cenários dinâmicos, sem a necessidade de longos períodos de repouso, mantendo níveis adequados de precisão.

Como solução, propõe-se o desenvolvimento de um artefato baseado em Reinforcement Learning capaz de aprender a partir de dados operacionais da bateria. Espera-se que o modelo seja capaz de estimar ou auxiliar no controle do SOC, demonstrando sua viabilidade como alternativa aos métodos tradicionais.

2. Estado da Arte

As baterias de íon de lítio tornaram-se uma das tecnologias de armazenamento de energia mais utilizadas devido à sua alta densidade energética, longa vida útil e baixa taxa de autodescarga. Essas baterias são amplamente aplicadas em veículos elétricos, sistemas de armazenamento de energia renovável e dispositivos eletrônicos portáteis devido à sua eficiência energética e confiabilidade operacional [1].

O aumento da utilização dessas baterias exige métodos avançados de monitoramento capazes de garantir o funcionamento seguro e eficiente ao longo do tempo [4]. Os métodos de medição são tradicionalmente divididos naqueles baseados em medições físicas, métodos baseados em modelos matemáticos e métodos orientados a dados [2][3][6].

Para atender a essas necessidades, os sistemas de gerenciamento de baterias, conhecidos como Battery Management Systems (BMS), são utilizados para monitorar e controlar diversos parâmetros operacionais da bateria [4]. O BMS é responsável por supervisionar variáveis como tensão, corrente e temperatura, além de garantir proteção contra condições críticas como sobrecarga e descarga profunda. Entre as funções mais importantes do BMS está a estimativa precisa do Estado de Carga (SOC), essencial para manter o desempenho adequado do sistema [1].

Diversos métodos tradicionais foram desenvolvidos para estimar o SOC em baterias de íon de lítio, sendo o método de Coulomb Counting um dos mais utilizados devido à sua simplicidade de implementação. Outro método amplamente empregado é o Open Circuit Voltage (OCV), que relaciona a tensão da bateria ao nível de carga disponível. Além disso, técnicas baseadas

em filtros matemáticos, como o Filtro de Kalman, têm sido utilizadas para melhorar a precisão das estimativas em condições variáveis de operação [2].

Apesar da ampla utilização desses métodos tradicionais, eles apresentam limitações significativas quando aplicados em cenários reais e dinâmicos. Esses métodos frequentemente dependem de períodos de repouso da bateria para fornecer medições mais precisas, o que nem sempre é viável em aplicações práticas [3]. Além disso, a presença de ruídos nos sensores e variações de carga podem reduzir significativamente a precisão das estimativas obtidas por métodos convencionais [2].

Com o avanço das tecnologias computacionais, abordagens baseadas em Machine Learning passaram a ser utilizadas para melhorar a estimativa do SOC em baterias modernas. O Machine Learning permite que modelos aprendam padrões complexos a partir de dados históricos, tornando possível lidar com comportamentos não lineares característicos das baterias de íon de lítio. Essas abordagens são particularmente úteis em sistemas que operam sob diferentes condições ambientais e perfis de carga variáveis [6].

Entre as técnicas de Machine Learning, os métodos de Deep Learning têm demonstrado resultados promissores na estimativa do SOC devido à sua capacidade de modelar relações complexas em séries temporais. Modelos como Long Short-Term Memory (LSTM) e Deep Neural Networks (DNN) são frequentemente utilizados para capturar dependências temporais e melhorar a precisão das previsões [5]. Esses modelos são capazes de lidar com grandes volumes de dados e identificar padrões que não seriam facilmente detectados por métodos tradicionais [6].

Além das abordagens supervisionadas, o Reinforcement Learning (RL) tem sido explorado como uma alternativa promissora para o gerenciamento inteligente de baterias [3]. O RL baseia-se em um sistema de interação entre agente e ambiente, no qual decisões são tomadas com base em recompensas obtidas ao longo do tempo [7]. Essa abordagem permite que o sistema aprenda estratégias eficientes de controle e estimativa do SOC diretamente a partir de dados operacionais, tornando-se adequada para sistemas dinâmicos [5].

Para avaliar o desempenho dos modelos utilizados na estimativa do SOC, diferentes métricas de avaliação são empregadas na literatura científica. Entre as métricas mais comuns estão o Mean Absolute Error (MAE) e o Root Mean Square Error (RMSE), que medem a diferença entre valores estimados e reais do SOC [6]. Essas métricas permitem comparar diferentes métodos e identificar soluções mais eficientes e precisas para aplicações em sistemas

reais [4].

3. Materiais e Metodos

Esta seção detalha os procedimentos adotados para o desenvolvimento do sistema de Reinforcement Learning visando a melhoria da precisão da estimativa do Estado da carga (*State of Charge* - SOC) em cenários dinâmicos.

Ela abrange a descrição do conjunto de dados utilizado, as etapas de pré-processamento, a arquitetura dos modelos empregados e o protocolo experimental definido para a avaliação. A Figura 1 apresenta um fluxograma geral das etapas metodológicas




Figure 1: Fluxograma da Solução Desenvolvida

3.0.1. Base de Dados (Dataset)

O estudo utilizou o conjunto de dados disponível no *IEEE DataPort*, [8]. Esta base de dados é composta por 6 células de baterias de íon de lítio previamente utilizadas, sendo 3 células de segunda vida e 3 células de terceira vida útil.

As tabelas 1 e 2 indicam as células utilizadas durante a pesquisa, sua capacidade das células e a saúde restante de cada bateria

Célula	Capacidade	Saúde
Célula 001	1870 mAh	85%
Célula 002	1804 mAh	82%
Célula 003	1320 mAh	60%

Table 1: Células de Segunda Vida

Célula	Capacidade	Saúde
Célula 004	990 mAh	45%
Célula 005	530 mAh	24%
Célula 006	490 mAh	22%

Table 2: Células de Terceira Vida

Cada célula passou por 20 ciclos de descarga sob corrente constante, variando a resistência, com um aumento de 0.5 OHM a cada 4 ciclos. As informações captadas durante esses ciclos de descarga encontram-se na tabela 3, as quais são essenciais para a predição do SOC

Atributo	Descrição
Data	Data e hora do experimento
Voltagem (V)	Voltagem terminal da célula
Corrente (A)	Corrente de Descarga
Potência (W)	Potência instantânea de descarga
Resistência (Ω)	Valor da resistência aplicada no ciclo de descarga
Temperatura ($^{\circ}\text{C}$)	Temperatura da superfície da célula

Table 3: Informações captadas durante a descarga

3.0.2. Pré-Processamento dos dados

Durante o estudo e a análise da base de dados, descrita na Seção 3.0.1, observou-se que o Estado de Carga (*State of Charge* - SOC) não estava

disponível explicitamente como uma característica do conjunto de dados. Dessa forma, foi necessária a realização de uma etapa de pré-processamento para obtenção dessa informação.

Para isso, a base de dados foi manipulada de modo a permitir a identificação e o cálculo do SOC ao longo de cada ciclo de descarga da bateria. Como etapa inicial, realizou-se a identificação e a segmentação dos ciclos de operação presentes nos dados.

A identificação dos ciclos foi realizada por meio da análise da tensão da célula ao longo do tempo. Cada ciclo tem início quando a célula se encontra carregada, apresentando tensão próxima de 4.2 V, e termina quando a tensão atinge seu valor terminal, aproximadamente 0.2 V, momento em que se inicia um novo processo de carregamento e, conseqüentemente, um novo ciclo. As Figuras 2 e 3 ilustram o comportamento da tensão ao longo dos ciclos e o critério adotado para sua identificação.




Figure 2: Célula 2 - Ciclo 0




Figure 3: Celula 3 - Ciclo 7

Após a identificação dos ciclos de descarga, foi realizado o cálculo do Estado de Carga (*SOC*) por meio do método de Contagem de Coulombs (*Coulomb Counting*). Esse método estima a quantidade de carga remanescente na bateria a partir da integração da corrente ao longo do tempo.

Inicialmente, foi calculado o intervalo de tempo entre amostras consecutivas, sendo posteriormente convertido para horas. Em seguida, para cada ciclo de descarga, foi determinada a variação do SOC a partir da corrente medida e da capacidade nominal da célula, conforme apresentado na Equação 3.

$$\Delta SOC = \frac{-I \cdot \Delta t}{C} \quad (1)$$

em que I representa a corrente da bateria, Δt corresponde ao intervalo de tempo entre duas amostras consecutivas e C é a capacidade nominal da célula em ampère-hora (Ah).

A partir da variação acumulada de carga, o SOC foi obtido considerando que cada ciclo se inicia com a bateria totalmente carregada, conforme mostrado na Equação 3.

$$SOC = 1 - \sum \Delta SOC \quad (2)$$

Como os ciclos apresentam diferentes capacidades efetivas devido ao envelhecimento das células, foi aplicada uma etapa adicional de normalização

Min-Max em cada ciclo de descarga. Esse procedimento garante que os valores de SOC permaneçam limitados ao intervalo entre 0 e 1, preservando a evolução relativa da descarga dentro de cada ciclo. A normalização foi realizada de acordo com a Equação 3.

$$SOC_{norm} = \frac{SOC - SOC_{min}}{SOC_{max} - SOC_{min}} \quad (3)$$

Por fim, os valores obtidos foram limitados ao intervalo $[0, 1]$, garantindo consistência numérica e evitando valores fora da faixa fisicamente admissível para o estado de carga da bateria.

3.0.3. Treinamento do Modelo Base (Long Short Term Memory - LSTM)

Após o pré-processamento dos dados e a definição do Estado de Carga (SOC) como variável alvo, foi desenvolvido um pipeline de aprendizado de máquina baseado em redes neurais recorrentes do tipo *Long Short-Term Memory (LSTM)* para a predição do SOC.

Inicialmente, os dados foram organizados em três diferentes cenários experimentais de divisão entre treinamento e teste, visando avaliar a capacidade de generalização do modelo sob diferentes condições: (i) treinamento com uma bateria e teste com cinco baterias, (ii) treinamento com três baterias e teste com três baterias, e (iii) treinamento com cinco baterias e teste com uma bateria.

As variáveis de entrada utilizadas no modelo incluem tensão, corrente, potência, resistência e temperatura, sendo todas normalizadas por meio de escalonamento Min-Max. O SOC também foi escalonado para o intervalo $[0, 1]$, garantindo consistência numérica durante o treinamento.

Para capturar a dependência temporal dos dados, foi aplicada uma janela deslizante (*sliding window*) de tamanho 20, transformando a série temporal em sequências estruturadas como entrada para a rede LSTM.

A arquitetura do modelo consiste em duas camadas LSTM empilhadas, seguidas por camadas de dropout para redução de overfitting e uma camada densa de saída responsável pela regressão do SOC. O modelo foi treinado utilizando a função de perda erro quadrático médio (*Mean Squared Error - MSE*).

A avaliação do desempenho foi realizada por meio do erro quadrático médio da raiz (*Root Mean Squared Error - RMSE*), calculado após a retransformação dos valores previstos para a escala original.

3.0.4. Treinamento do Modelo Alvo (*Reinforcement Learning*)

Além dos modelo supervisionado, foi investigada a aplicação de Aprendizado por Reforço (*Reinforcement Learning*) para a estimação do Estado de Carga (SOC) das baterias. Para isso, foi desenvolvido um ambiente personalizado utilizando a biblioteca Gymnasium, no qual cada observação é composta pelas variáveis de tensão, corrente, potência, resistência e temperatura da célula.

O ambiente foi modelado de forma que, a cada instante de tempo, o agente recebesse como estado os valores das variáveis monitoradas e produzisse uma ação correspondente à estimativa do SOC. A qualidade da estimativa foi avaliada por meio de uma função de recompensa baseada no erro quadrático entre o SOC previsto e o SOC real. Dessa forma, o agente foi incentivado a minimizar o erro de predição ao longo do processo de treinamento.

Como algoritmo de aprendizado por reforço foi utilizado o Proximal Policy Optimization (PPO), amplamente empregado em problemas de otimização contínua devido à sua estabilidade e eficiência computacional. O treinamento foi realizado durante 200.000 passos de interação com o ambiente.

Diferentemente dos experimentos realizados com redes LSTM, a divisão dos dados para treinamento e validação foi efetuada dentro de cada célula individualmente. Para cada bateria, os ciclos de descarga foram divididos em duas partes de igual tamanho, sendo a primeira metade utilizada para treinamento do agente e a segunda metade destinada à validação. Essa estratégia permitiu avaliar a capacidade do modelo em generalizar seu aprendizado para dados futuros da mesma célula.

Após o treinamento, o agente foi avaliado no conjunto de validação, produzindo estimativas de SOC para cada amostra. O desempenho foi mensurado por meio da métrica RMSE (*Root Mean Squared Error*), calculada a partir da diferença entre os valores reais e os valores previstos de SOC.

4. Resultados e Discussões

Após o treinamento e a validação dos modelos propostos, os resultados foram organizados de acordo com os cenários experimentais definidos na metodologia. O desempenho foi avaliado por meio da métrica *Root Mean Squared Error* (RMSE), utilizada para quantificar a diferença entre os valores reais e previstos de SOC.

Os resultados obtidos pelo modelo LSTM, apresentados na Tabela 4, demonstram valores de RMSE próximos entre os diferentes cenários de treina-

mento e validação, variando entre 0,181 e 0,189. Essa baixa variação indica que o modelo foi capaz de manter um desempenho consistente mesmo quando avaliado em baterias não utilizadas durante o treinamento, evidenciando sua capacidade de generalização.

Modelo - <i>LSTM</i>	<i>Root Mean Squared Error - RMSE</i>
1 treinamento - 5 validação	0.181
3 treinamento - 3 validação	0.185
5 treinamento - 1 validação	0.189

Table 4: Resultados Obtidos - *LSTM*

A Tabela 5 apresenta os resultados do modelo baseado em Aprendizado por Reforço. Nesse caso, o treinamento e a validação foram realizados individualmente para cada célula, utilizando metade dos ciclos para treinamento e a outra metade para validação. Os valores de RMSE variaram entre 0,0985 e 0,2746, indicando que o desempenho do agente depende das características específicas de cada bateria.

Modelo - <i>RL</i>	<i>Root Mean Squared Error - RMSE</i>
Célula 1	0.2553
Célula 2	0.2746
Célula 3	0.1921
Célula 4	0.1204
Célula 5	0.1359
Célula 6	0.0985

Table 5: Resultados Obtidos - *RL*

Além da precisão, também foram avaliados os tempos de execução dos modelos, conforme apresentado na Tabela 6. O modelo LSTM demandou aproximadamente 2 horas e 30 minutos para treinamento e validação, enquanto o modelo baseado em Aprendizado por Reforço concluiu o processo em cerca de 35 minutos.

Modelos	Tempo Total
Modelo Base (<i>LSTM</i>)	2 horas 30 minutos
Modelo Alvo (<i>RL</i>)	35 minutos

Table 6: Resultados Obtidos

De modo geral, os resultados indicam que o modelo *LSTM* apresentou maior capacidade de generalização entre diferentes baterias, enquanto o modelo baseado em Aprendizado por Reforço mostrou-se uma alternativa eficiente para a modelagem de células específicas, apresentando menor custo computacional e desempenho competitivo em determinados casos.

5. Conclusão

A estimativa precisa do Estado de Carga é um dos principais desafios no gerenciamento de baterias de íon de lítio, especialmente em aplicações que operam sob condições dinâmicas e variáveis. Neste trabalho, foi realizada uma investigação sobre a aplicação de técnicas de Reinforcement Learning como alternativa aos métodos tradicionais e às abordagens supervisionadas para a estimativa do SOC.

Inicialmente, foi desenvolvido um processo de pré-processamento capaz de identificar os ciclos de descarga e calcular o SOC por meio do método de Coulomb Counting, permitindo a construção de uma base adequada para treinamento dos modelos. Como modelo de referência, foi implementada uma rede *Long Short-Term Memory (LSTM)*, amplamente utilizada na literatura devido à sua capacidade de capturar dependências temporais presentes nos dados de baterias.

Os resultados obtidos pelo modelo base demonstram a viabilidade da utilização de técnicas de aprendizado de máquina para a predição do SOC em baterias de diferentes níveis de degradação. Além disso, a pesquisa estabeleceu uma estrutura experimental que possibilita a comparação entre abordagens supervisionadas e técnicas baseadas em *Reinforcement Learning*.

Espera-se que a aplicação da Aprendizagem por Reforço permita uma maior adaptação a cenários operacionais dinâmicos, reduzindo a dependência de períodos de repouso da bateria e possibilitando decisões mais eficientes a partir da interação contínua com o ambiente. Dessa forma, essa abordagem apresenta potencial para contribuir com o desenvolvimento de sistemas de gerenciamento de baterias mais inteligentes, robustos e adequados às demandas de veículos elétricos e sistemas modernos de armazenamento de energia.

Logo, o *Reinforcement Learning* apresenta potencial para estimar o Estado de Carga (*SOC*) de baterias de forma mais eficiente em ambientes dinâmicos e sujeitos a constantes variações operacionais. A metodologia proposta neste estudo pode servir como base para futuras pesquisas e para o desenvolvimento de Sistemas Inteligentes de Gerenciamento de Baterias.

References

- [1] V. Selvaraj, I. Vairavasundaram, A comprehensive review of state of charge estimation in lithium-ion batteries used in electric vehicles, *Journal of Energy Storage* 72 (2023) 108777. doi:<https://doi.org/10.1016/j.est.2023.108777>. URL <https://www.sciencedirect.com/science/article/pii/S2352152X23021746>
- [2] K. Luo, X. Chen, H. Zheng, Z. Shi, A review of deep learning approach to predicting the state of health and state of charge of lithium-ion batteries, *Journal of Energy Chemistry* 74 (2022) 159–173. doi:<https://doi.org/10.1016/j.jechem.2022.06.049>. URL <https://www.sciencedirect.com/science/article/pii/S2095495622003564>
- [3] Mortabit, Idriss, Rachid, Aziz, Errifai, Nidale, Boudmane, Bilal, Estimation of battery soc using reinforcement learning, *EPJ Web Conf.* 330 (2025) 06006. doi:[10.1051/epjconf/202533006006](https://doi.org/10.1051/epjconf/202533006006). URL <https://doi.org/10.1051/epjconf/202533006006>
- [4] M. Kim, K. Kim, J. Kim, J. Yu, S. Han, State of charge estimation for lithium ion battery based on reinforcement learning, *IFAC-PapersOnLine* 51 (28) (2018) 404–408, 10th IFAC Symposium on Control of Power and Energy Systems CPES 2018. doi:<https://doi.org/10.1016/j.ifacol.2018.11.736>. URL <https://www.sciencedirect.com/science/article/pii/S2405896318334566>
- [5] I. Saba, M. Tariq, M. Ullah, H. V. Poor, Deep reinforcement learning based state of charge estimation and management of electric vehicle batteries, *IET Smart Grid* 6 (2023) 422–431. arXiv:<https://digital-library.theiet.org/doi/pdf/10.1049/stg2.12110>, doi:[10.1049/stg2.12110](https://doi.org/10.1049/stg2.12110). URL <https://digital-library.theiet.org/doi/abs/10.1049/stg2.12110>
- [6] S. Guo, L. Ma, A comparative study of different deep learning algorithms for lithium-ion batteries on state-of-charge estimation, *Energy* 263 (2023) 125872. doi:<https://doi.org/10.1016/j.energy.2022.125872>. URL <https://www.sciencedirect.com/science/article/pii/S036054422202758X>
- [7] R. S. Sutton, *Reinforcement Learning: An Introduction*, MIT Press, Cambridge, MA, 2018.

- [8] J. D. Gotz, N. Mendes, A. de Souza Britto Junior, J. R. Galvão, F. C. Corrêa, A. A. Badin, Experimental dataset of retired batteries (first-life, second-life and third-life) discharged at constant load rate (2026). doi:10.21227/mm0k-2w93.
URL <https://dx.doi.org/10.21227/mm0k-2w93>